



가톨릭대학교  
THE CATHOLIC UNIVERSITY OF KOREA

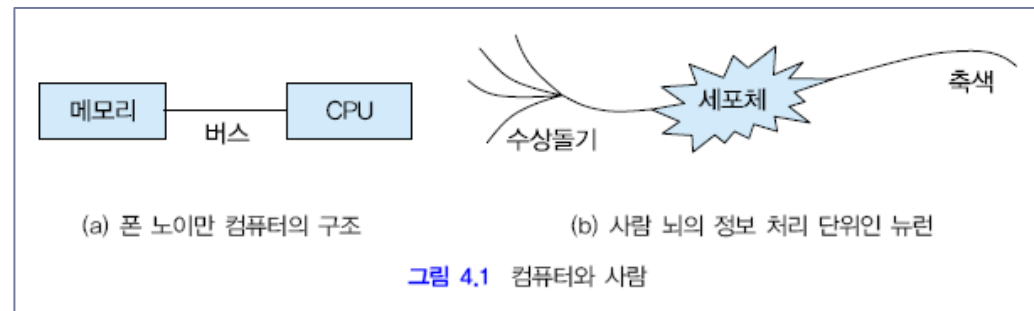
# 기계학습응용

## -인공신경망 리뷰-

미디어기술콘텐츠학과  
강호철

# 배경

- 뇌의 정보처리 방법 모방
  - 지능 컴퓨터에 도전
  - 인공 신경망(ANN, Artificial Neural Network)
    - 1940대 개발 (디지털 컴퓨터와 탄생 시기가 유사함)
    - 인간 지능에 필적하는 컴퓨터 개발이 목표
- 컴퓨터와 두뇌의 비교
  - 폰 노이만 컴퓨터
    - 순차 명령어 처리기
  - 두뇌
    - 뉴런으로 구성
    - 고도의 병렬 명령어 처리기



# 배경

---

## ■ 간략한 역사

- 1943, McCulloch과 Pitts 최초 신경망 제안
- 1949, Hebb의 학습 알고리즘
- 1958, Rosenblatt 퍼셉트론
- Widrow와 Hoff, Adaline과 Madaline
- 1960대, 신경망의 과대 포장
- 1969, Minsky와 Papert, Perceptrons라는 저서에서 퍼셉트론 한계 지적
  - 퍼셉트론은 선형 분류기에 불과하고 XOR도 해결 못함
  - 이후 신경망 연구 퇴조
- 1986, Rumelhart, Hinton, 그리고 Williams, 다층 퍼셉트론과 오류 역전파 학습 알고리즘
  - 필기 숫자 인식같은 복잡하고 실용적인 문제에 높은 성능
  - 신경망 연구 다시 활기 찾음
  - 현재 가장 널리 활용되는 문제 해결 도구



# 수학적 모델의 신경망

---

- 신경망 특성
  - 학습 가능
  - 뛰어난 일반화 능력
  - 병렬 처리 가능
  - 현실적 문제에서 우수한 성능
  - 다양한 문제 해결 도구 (분류, 예측, 함수 근사화, 합성, 평가,...)
- 절반의 성공
  - 인간 지능에 필적하는 컴퓨터 만들지 못함
  - 제한된 환경에서 실용적인 시스템 만드는데 크게 기여 (실용적인 수학적 모델로서 자리매김)
  - 딥러닝으로 발전



# 수학적 모델의 신경망


---

- 새로운 개념들 등장
  - 층
  - 노드와 가중치
  - 학습
  - 활성화 함수
- MLP의 초석이 됨

# 퍼셉트론

- 개념


- 다수의 신호를 입력으로 받아 하나 혹은 여러 신호 출력
  - 신호는 흐름을 가짐
  - 신호의 총합이 임계치를 넘으면 1, 아니면 0 출력
  - 가중치는 해당 신호의 중요한 정도




# 퍼셉트론

## ■ 구조


- 입력층:  $d+1$ 개의 노드 (특징 벡터  $\mathbf{x}=(x_1, \dots, x_d)^T$ )
- 출력층: 한 개의 노드 (따라서 2-부류 분류기)
- 에지와 가중치



(a) 전체 구조



(b) 출력 노드의 연산



(c) 활성 함수

그림 4.2 퍼셉트론의 구조

# 퍼셉트론


## ■ 예제

$$\mathbf{a} = (0,0)^T, t_a = -1$$


$$\mathbf{b} = (1,0)^T, t_b = 1$$

$$\mathbf{c} = (0,1)^T, t_c = 1$$


$$\mathbf{d} = (1,1)^T, t_d = 1$$



(a) OR 분류 문제



(b) OR 분류기로서 퍼셉트론



(c) 퍼셉트론은 선형 분류기

그림 4.3 퍼셉트론의 예

이 퍼셉트론은  $\mathbf{w}=(1,1)^T, b=-0.5$


따라서 결정 직선은  $d(\mathbf{x}) = x_1 + x_2 - 0.5$

- 샘플 **c** 를 인식해 보자. 맞추나?  $y = \tau(\mathbf{w}^T \mathbf{c} + b) = \tau((1,1) \begin{pmatrix} 0 \\ 1 \end{pmatrix} - 0.5) = \tau(0.5) = 1$
- 나머지 **a, b, d** 는?



# 단순 논리 회로

- AND 게이트
  - $y$ 가 참인 경우?
  - 거짓인 경우?
  - AND를 만족하는 매개변수 쌍
    - $(w_1=0.5, w_2=0.5, \text{theta}=0.7)$
    - $(0.5, 0.5, 0.8)$
    - $(1.0, 1.0, 1.0)$
    - .....




# 단순 논리 회로

- NAND 게이트

- $y$ 가 참/거짓인 경우?
- NAND를 만족하는 매개변수 쌍
  - ( $w_1 = -0.5, w_2 = -0.5, \theta = -0.7$ )
  - .....

- OR 게이트

- $y$ 가 참/거짓인 경우?
- OR를 만족하는 매개변수 쌍
  - ( $w_1 = 1.0, w_2 = 1.0, \theta = 0.5$ )
  - .....





# 퍼셉트론

## ■ 퍼셉트론 학습

- 퍼셉트론 학습이란? 훈련 집합  $X = \{(\mathbf{x}_1, t_1), (\mathbf{x}_2, t_2), \dots, (\mathbf{x}_N, t_N)\}$  이 주어졌을 때 이들을 모두 옳게 분류하는 퍼셉트론 (즉  $\mathbf{w}$ 와  $b$ )을 찾아라. 샘플  $(\mathbf{x}_i, t_i)$ 에서  $\mathbf{x}_i$ 는 특징 벡터이고  $t_i$ 는 부류 표지로서  $\mathbf{x}_i \in \omega_1$ 이면  $t_i = 1$ 이고  $\mathbf{x}_i \in \omega_2$ 이면  $t_i = -1$ 이다.  $X$ 는 선형 분리 가능하다고 가정한다.<sup>3</sup>

## □ 예) AND 분류 문제

$$\begin{array}{llll} \mathbf{a}=(0,0)^T & \mathbf{b}=(1,0)^T & \mathbf{c}=(0,1)^T & \mathbf{d}=(1,1)^T \\ t_a=-1 & t_b=-1 & t_c=-1 & t_d=1 \end{array}$$



# 퍼셉트론

- 노드의 연산
  - 입력 노드: 받은 신호를 단순히 전달
  - 출력 노드: 합 계산과 활성화 함수 계산

$$\left. \begin{aligned} y = \tau(s) &= \tau\left(\sum_{i=1}^d w_i x_i + b\right) = \tau(\mathbf{w}^T \mathbf{x} + b) \\ \text{이때 } \tau(s) &= \begin{cases} +1, s \geq 0 \\ -1, s < 0 \end{cases} \end{aligned} \right\} \quad (4.2)$$

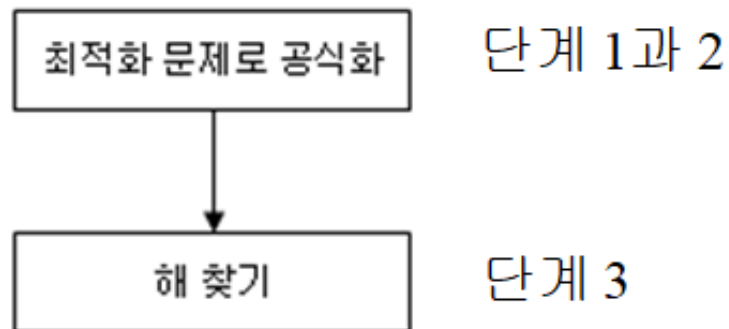
- 퍼셉트론은 선형 분류기

$$\left. \begin{aligned} d(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b > 0 \text{ 이면 } \mathbf{x} \in \omega_1 \\ d(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b < 0 \text{ 이면 } \mathbf{x} \in \omega_2 \end{aligned} \right\} \quad (4.3)$$



# 퍼셉트론 학습

- (Review) 일반적인 학습 알고리즘 설계 과정
  - 단계 1: 분류기 구조 정의와 분류 과정의 수학적 정의
  - 단계 2: 분류기 품질 측정용 비용함수  $J(\Theta)$  정의
  - 단계 3:  $J(\Theta)$ 를 최적화하는  $\Theta$ 를 찾는 알고리즘 설계



# 퍼셉트론 학습

---

- 단계 1
  - 식 (4.2)
  - 매개변수 집합  $\Theta = \{\mathbf{w}, b\}$
- 단계 2
  - 분류기 품질을 측정하는  $J(\Theta)$ 를 어떻게 정의할 것인가?

$$J(\Theta) = \sum_{\mathbf{x}_k \in Y} (-t_k)(\mathbf{w}^T \mathbf{x}_k + b) \quad (4.4)$$

- $Y$ : 오분류된 샘플 집합
- $J(\Theta)$ 는 항상 양수
- $Y$ 가 공집합이면  $J(\Theta) = 0$
- $|Y|$ 가 클수록  $J(\Theta)$  큼

# 퍼셉트론 학습

## ■ 단계 3

- $\mathcal{J}(\Theta)=0$ 인  $\Theta$ 를 찾아라.
- 내리막 경사법 (Gradient descent method)
  - 현재 해를  $-\frac{\partial \mathcal{J}}{\partial \Theta}$  방향으로 이동
  - 학습률  $\rho$ 를 곱하여 조금씩 이동





그림 11.9 내리막 경사법

# 경사하강법 (Gradient Descent)


- 경사도(기울기)
  - 모든 변수의 편미분을 벡터로 정리한 것
  - 경사도가 가리키는 쪽은 각 장소에서 함수의 출력 값을 가장 줄이는 방향임
- 경사하강법
  - 경사도를 이용하여 손실함수의 최소값을 찾는 방법





# 경사하강법 (Gradient Descent)

## ▪ Convex Function



- 미분값이 0이라고 무조건 최솟값은 아닙니다.
- **최댓값**일 수도 있습니다.
- 최솟값은 아니지만 미분 값이 0인 곳을 **Local Minimum**이라고 합니다.

# 경사하강법 (Gradient Descent)


- 개념

- 현 위치에서 기울어진 방향으로 일정 거리만큼 이동
- 이동한 거리에서 다시 경사도 구하고 이동
- 위의 과정을 반복

$$x_0 = x_0 - \eta \frac{\partial f}{\partial x_0}$$


$$x_1 = x_1 - \eta \frac{\partial f}{\partial x_1}$$

- 에타: 학습률(learning rate)
- hyper-parameter



# 경사하강법 (Gradient Descent)

- 개념
  - 학습률(learning rate)



# 퍼셉트론 학습

- 전체 알고리즘
  - 초기해 설정
  - 멈춤조건이 만족될때까지 현재 해를 조금씩 이동

$$\Theta(h+1) = \Theta(h) - \rho(h) \frac{\partial J(\Theta)}{\partial \Theta} \quad (4.5)$$

$$\left. \begin{aligned} \frac{\partial J(\Theta)}{\partial \mathbf{w}} &= \sum_{\mathbf{x}_k \in Y} (-t_k) \mathbf{x}_k \\ \frac{\partial J(\Theta)}{\partial b} &= \sum_{\mathbf{x}_k \in Y} (-t_k) \end{aligned} \right\} \quad (4.6)$$

$$\left. \begin{aligned} \mathbf{w}(h+1) &= \mathbf{w}(h) + \rho(h) \sum_{\mathbf{x}_k \in Y} t_k \mathbf{x}_k \\ b(h+1) &= b(h) + \rho(h) \sum_{\mathbf{x}_k \in Y} t_k \end{aligned} \right\} \quad (4.7)$$

# 퍼셉트론

## 알고리즘 [4.1] 퍼셉트론 학습 (배치 모드 batch mode)

입력: 훈련 집합  $X = \{(x_1, t_1), (x_2, t_2), \dots, (x_N, t_N)\}$ , 학습률  $\rho$

출력: 퍼셉트론 가중치  $w, b$

알고리즘:

1.  $w$ 와  $b$ 를 초기화한다.
2. **repeat** {
3.    $Y = \emptyset$ ;
4.   **for** ( $i = 1$  to  $N$ ) {
5.      $y = \tau(w^T x_i + b)$ ;     // (4.2)로 분류를 수행함
6.     **if** ( $y \neq t_i$ )  $Y = Y \cup x_i$ ;   // 오분류된 샘플 수집
7.   }
8.    $w = w + \rho \sum_{x_k \in Y} t_k x_k$ ;     // (4.7)로 가중치 갱신
9.    $b = b + \rho \sum_{x_k \in Y} t_k$ ;
10. } **until** ( $Y = \emptyset$ );
11.  $w$ 와  $b$ 를 저장한다.

# 퍼셉트론



## ■ 예제 - 학습

$$\mathbf{a} = (0,0)^T, t_a = -1$$

$$\mathbf{b} = (1,0)^T, t_b = 1$$

$$\mathbf{c} = (0,1)^T, t_c = 1$$

$$\mathbf{d} = (1,1)^T, t_d = 1$$



- $\rho = 0.4$ 로 설정
- 초기값은  $\mathbf{w}(0) = (-0.5, 0.75)^T, b(0) = 0.375$
- $d(\mathbf{x}) = -0.5x_1 + 0.75x_2 + 0.375$
- $Y(\text{오분류 샘플}) = \{\mathbf{a}, \mathbf{b}\}$
- 가중치 갱신

} 반복


$$8. \quad \mathbf{w} = \mathbf{w} + \rho \sum_{\mathbf{x}_k \in Y} t_k \mathbf{x}_k ;$$

$$9. \quad b = b + \rho \sum_{\mathbf{x}_k \in Y} t_k ;$$

# 퍼셉트론

## ■ 예제 - 학습

- $w(1) = ?, b(1) = ?, Y = ?$
- $w(2) = ?, b(2) = ?, Y = ?$
- $w(3) = ?, b(3) = ?, Y = ?$
- $w(4) = ?, b(4) = ?, Y = ?$
- .....
- 최종  $w = ?, b = ?$



### 알고리즘 [4.1] 퍼셉트론 학습 (배치 모드 batch mode)

입력: 훈련 집합  $X = \{(x_1, t_1), (x_2, t_2), \dots, (x_N, t_N)\}$ , 학습률  $\rho$


출력: 퍼셉트론 가중치  $w, b$

알고리즘:


1.  $w$ 와  $b$ 를 초기화한다.
2. **repeat** {
3.    $Y = \emptyset$ ;
4.   **for** ( $i = 1$  to  $N$ ) {
5.      $y = \tau(w^T x_i + b)$ ;   // (4.2)로 분류를 수행함
6.     **if** ( $y \neq t_i$ )  $Y = Y \cup x_i$ ;   // 오분류된 샘플 수집
7.   }
8.    $w = w + \rho \sum_{x_i \in Y} x_i$ ;   // (4.7)로 가중치 갱신
9.    $b = b + \rho \sum_{x_i \in Y} t_i$ ;
10. } **until** ( $Y = \emptyset$ );
11.  $w$ 와  $b$ 를 저장한다.

# 다중 퍼셉트론

- 선형 분리 불가능한 상황
  - 퍼셉트론의 한계



(a) 선형 분리 가능



(b) 선형 분리 불가능

그림 4.5 선형 분리 가능과 불가능



# 다중 퍼셉트론

- XOR 문제
  - 퍼셉트론은 75% 정인식률이 한계
  - 이 한계를 어떻게 극복?
    - 두 개의 퍼셉트론 (결정 직선) 사용




그림 4.6 XOR 분류 문제의 해결

# 다중 퍼셉트론

- 두 단계에 걸쳐 문제 해결
  - 단계 1: 원래 특징 공간을 새로운 공간으로 매핑
  - 단계 2: 새로운 공간에서 분류

표 4.1 두 단계로 XOR 문제 해결

샘플	특징 벡터 (x)		첫 번째 단계		두 번째 단계
	$x_1$	$x_2$	퍼셉트론1	퍼셉트론2	퍼셉트론3
a	0	0	-1	+1	-1
b	1	0	+1	+1	+1
c	0	1	+1	+1	+1
d	1	1	+1	-1	-1

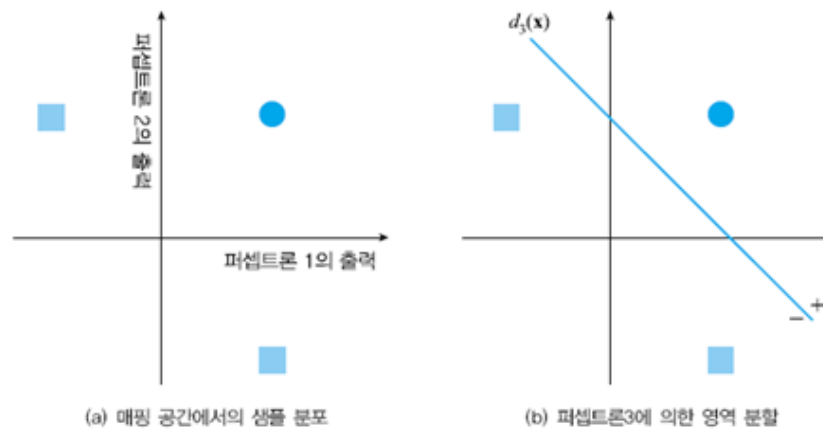


그림 4.7 새로운 공간에서의 샘플 분포와 영역 분할

# 다중 퍼셉트론

## ■ 다층 퍼셉트론 (MLP; Multi-layer perceptron)






그림 4.8 세 개의 퍼셉트론과 이들을 연결하여 만든 다층 퍼셉트론


# 다중 퍼셉트론

- XOR
  - AND, NAND, OR 이용



# 다중 퍼셉트론

- XOR
  - AND, NAND, OR 이용



© www.petervis.com

# 다중 퍼셉트론

## ■ 다층 퍼셉트론의 아키텍처

- 입력층, 은닉층, 출력층
- 가중치:  $u$ 와  $v$

## ■ 신경망은 일종의 함수

$$o = f(x)$$

$$\left. \begin{array}{l} z = p(x) \\ o = q(z) \end{array} \right\} \text{ 또는 } o = q(p(x))$$




그림 4.9 다층 퍼셉트론의 구조와 표기

# 다중 퍼셉트론

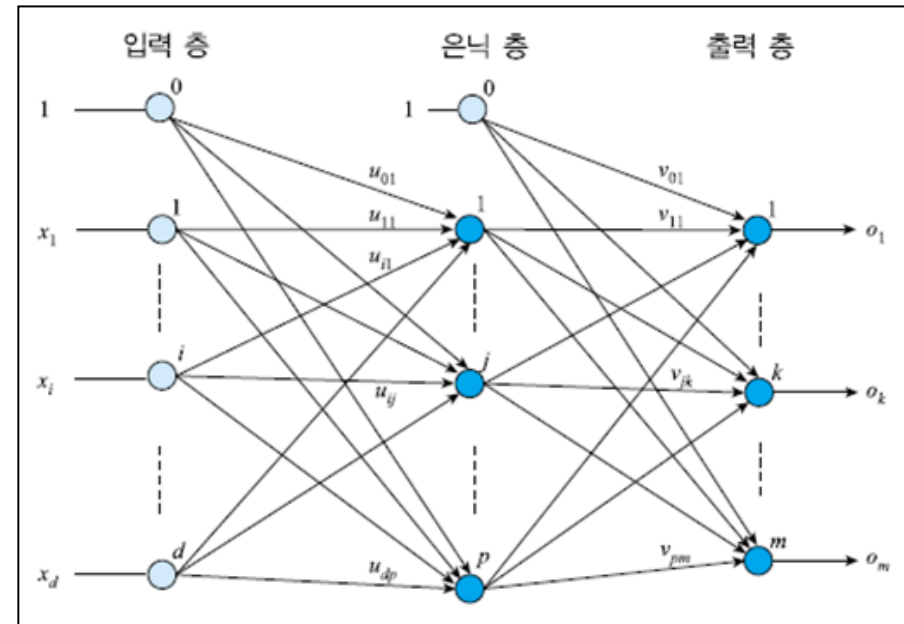
## ■ 전방 계산 (forward computation)

은닉 층의  $j$ 번째 노드,  $1 \leq j \leq p$ :

$$\left. \begin{aligned} z\_sum_j &= \sum_{i=1}^n x_i u_{ij} + u_{0j} \\ z_j &= \tau(z\_sum_j) \end{aligned} \right\} \quad (4.12)$$

출력 층의  $k$ 번째 노드,  $1 \leq k \leq m$ :

$$\left. \begin{aligned} o\_sum_k &= \sum_{j=1}^p z_j v_{jk} + v_{0k} \\ o_k &= \tau(o\_sum_k) \end{aligned} \right\}$$



# 다중 퍼셉트론

## ■ 활성 함수 (activation function)


### □ 시그모이드 사용

이진 시그모이드 함수:


$$\left. \begin{aligned} \tau_1(x) &= \frac{1}{1+e^{-\alpha x}} \\ \tau_1'(x) &= \alpha \tau_1(x)(1-\tau_1(x)) \end{aligned} \right\} \quad (4.14)$$

양극 시그모이드 함수:

$$\left. \begin{aligned} \tau_2(x) &= \frac{2}{1+e^{-\alpha x}} - 1 \\ \tau_2'(x) &= \frac{\alpha}{2}(1+\tau_2(x))(1-\tau_2(x)) \end{aligned} \right\} \quad (4.15)$$



(a) 이진 시그모이드



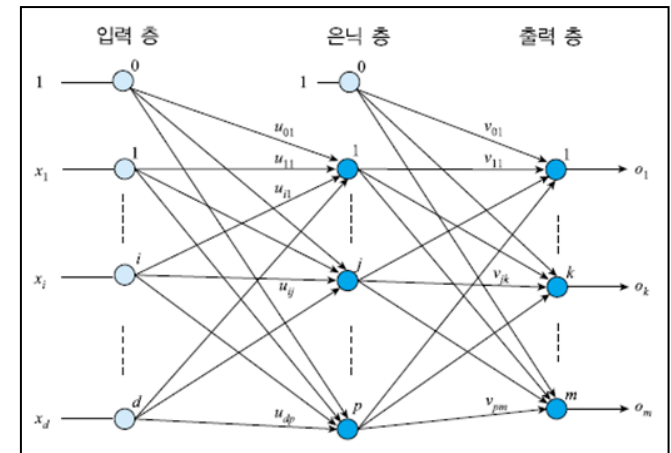
(b) 양극 시그모이드

그림 4.10 활성 함수로 널리 사용되는 두 가지 시그모이드 함수



# 다중 퍼셉트론

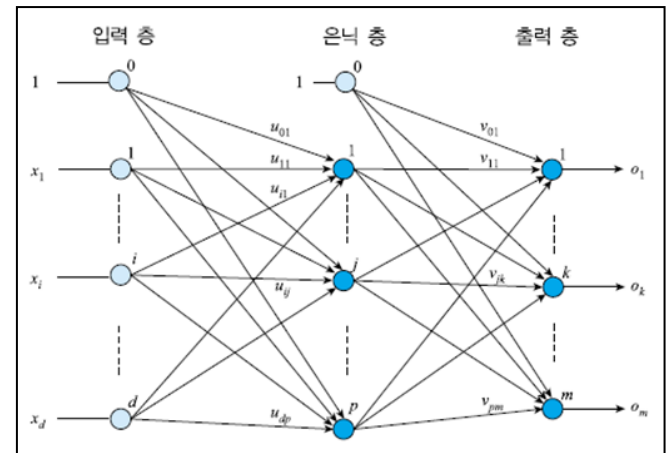
- 신경망 구조 설계 시 고려사항
  - 몇 개의 층을 둘 것 인가?
  - 층간의 연결은 어떻게 할 것인가?
  - 각 층에 있는 노드를 몇 개로 할 것인가?
  - 어떤 활성화 함수를 사용할 것인가?



# 다중 퍼셉트론

## ■ MLP의 학습이란?

- MLP 학습이란? 훈련 집합  $X = \{(\mathbf{x}_1, \mathbf{t}_1), (\mathbf{x}_2, \mathbf{t}_2), \dots, (\mathbf{x}_N, \mathbf{t}_N)\}$ 이 주어졌을 때 이들을 분류하는 다층 퍼셉트론 (즉  $\mathbf{u}$ 와  $\mathbf{v}$ )을 찾아라.  $(\mathbf{x}_i, \mathbf{t}_i)$ 에서  $\mathbf{x}_i$ 는 특징 벡터이고  $\mathbf{t}_i$ 는 부류 표지 벡터로서 class label vector (또는 목적 벡터라고도 target vector 함)  $\mathbf{x}_i \in \omega_j$ 이면  $\mathbf{t}_i = (0, \dots, 1, \dots, 0)^T$ 이다. 즉  $j$  번째 요소만 1이고 나머지 요소는 모두 0을 갖는다. 이것은 이진 모드를 사용할 때의 값이고 만일 양극 모드를 사용한다면  $\mathbf{t}_i = (-1, \dots, 1, \dots, -1)^T$ 로 하면 된다.



# 다중 퍼셉트론

- 단계 1
  - (4.12)와 (4.13)의 전방 계산이 분류기의 식
  - 매개변수 집합  $\Theta = \{\mathbf{u}, \mathbf{v}\}$
- 단계 2 (비용 함수 정의)

$$E = \frac{1}{2} \sum_{k=1}^m (t_k - o_k)^2 \quad (4.16)$$

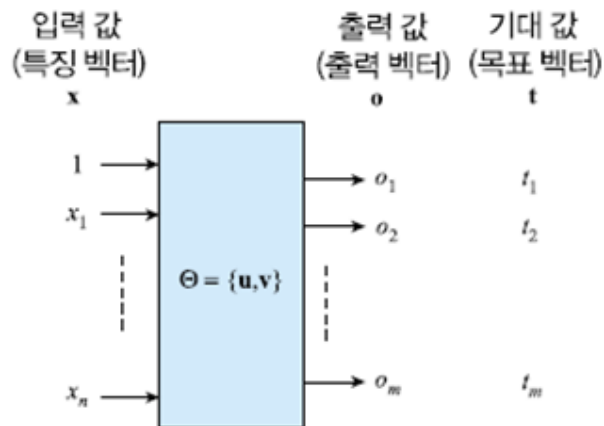


그림 4.12 다층 퍼셉트론의 입력, 출력, 그리고 기대값

# 다중 퍼셉트론

## ■ 단계 3 (최적 해 찾음)

- (4.16)의 오류를 줄이는 방향으로  $\theta$ 를 수정해 나감

$$\left. \begin{aligned} \mathbf{v}(h+1) &= \mathbf{v}(h) + \Delta \mathbf{v} = \mathbf{v}(h) - \rho \frac{\partial E}{\partial \mathbf{v}} \\ \mathbf{u}(h+1) &= \mathbf{u}(h) + \Delta \mathbf{u} = \mathbf{u}(h) - \rho \frac{\partial E}{\partial \mathbf{u}} \end{aligned} \right\} \quad (4.17)$$

### 알고리즘 [4.4] 다중 퍼셉트론 (MLP) 학습

입력: 훈련 집합  $X = \{(\mathbf{x}_1, \mathbf{t}_1), (\mathbf{x}_2, \mathbf{t}_2), \dots, (\mathbf{x}_N, \mathbf{t}_N)\}$ , 학습률  $\rho$

출력: 가중치  $\mathbf{u}$ 와  $\mathbf{v}$

알고리즘:

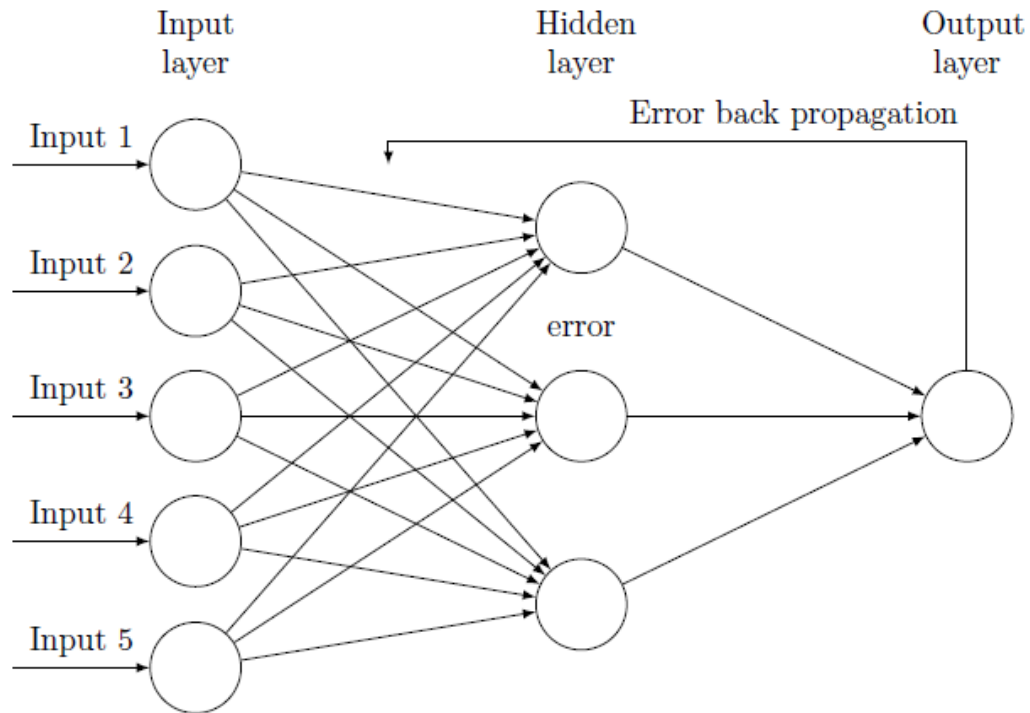
1.  $\mathbf{u}$ 와  $\mathbf{v}$ 를 초기화한다.
2. **repeat** {
3.   **for** ( $X$ 의 샘플 각각에 대해) {
4.     (4.12)와 (4.13)으로 전방 계산을 한다.
5.      $\frac{\partial E}{\partial \mathbf{v}}$ 와  $\frac{\partial E}{\partial \mathbf{u}}$ 를 계산한다.
6.     (4.17)로 새로운  $\mathbf{u}$ 와  $\mathbf{v}$ 를 계산한다.
7.   }
8. } **until** (stop-condition);

라인 5를 어떻게?

# 오류 역전파

- 개요


- 결과에서 입력 방향(역방향)으로 오차를 보내어 가중치를 재업데이트 하는 방법



# 오류 역전파

- 개요

- 결과에서 입력 방향(역방향)으로 오차를 보내어 가중치를 재업데이트 하는 방법



# 그밖에..

- 부연 설명
  - 네트워크 아키텍처
    - 은닉 층 개수, 은닉 노드 개수, ...
  - 가중치 초기화
  - 종료 시점
  - 활성함수
  - 학습률
  - .....




그림 4.15 일반화 기준에 따른 멈춤 조건

# 참고자료

---

- Introduction to Machine Learning with Python (파이썬 라이브러리를 활용한 머신러닝)
  - 안드레아스 밀러, 세라 가이도 지음 / 박해선 옮김
  - 한빛미디어, 2019
- 패턴인식
  - 오일석 지음
  - 교보문고, 2008
- 밑바닥 부터 시작하는 딥러닝
  - 사이토 고키 지음, 개앞맵시 옮김
  - 한빛미디어, 2017

